

Klasifikacija slika ljudskih akcija primenom konvolucione neuralne mreže

Katarina Bojović 22/0239

Tijana Aksović 22/0224

Sadržaj

1	Opis problema i skupa podataka	2
1.1	Primeri po klasama	2
1.2	Raspodela uzoraka po klasama	3
2	Predprocesiranje podataka	3
2.1	Skaliranje i normalizacija	3
2.2	Augmentacija podataka	4
3	Arhitektura modela	4
3.1	Transfer učenje – MobileNetV2	4
3.2	Celokupna arhitektura	5
3.3	Izbor aktivacionih funkcija	5
3.4	Kriterijumska funkcija	5
3.5	Optimizaciona metoda	6
4	Procedura treniranja	6
4.1	Faza 1: Treniranje FC dela	6
4.2	Faza 2: Fine-tuning	6
5	Zaštita od preobučavanja	6
5.1	Primenjene metode zaštite	7
6	Rezultati	7
6.1	Krive gubitka i tačnosti tokom treniranja	7
6.2	Performanse klasifikacije	8
6.2.1	Trening skup	8
6.2.2	Validacioni skup	9
6.2.3	Test skup	9
6.3	Matrice konfuzije	10
6.4	Primeri dobro i loše klasifikovanih slika	11
7	Zaključak	11

1 Opis problema i skupa podataka

Zadatak koji se rešava je višeklasna klasifikacija slika na osnovu prikazane ljudske akcije. Skup podataka koji je korišćen nosi naziv *Human Action Recognition* i sadrži ukupno **8 406 slika** raspoređenih u **10 klasa**, od kojih je 8 000 slika u trening skupu, a 406 slika u test skupu. Iz trening skupa izdvojen je i validacioni skup tako što je uzeto nasumičnih 20% slika.

Klase koje model treba da razlikuje su: *clapping*, *cycling*, *dancing*, *eating*, *fighting*, *hugging*, *laughing*, *running*, *sleeping*, *using_laptop*.

Sve slike su u RGB formatu i pre unošenja u model skaliraju se na rezoluciju 128×128 piksela.

1.1 Primeri po klasama


Na slici ispod prikazan je po jedan reprezentativni primer iz svake od deset klasa skupa podataka.



Slika 1: Po jedan primer slike iz svake klase skupa podataka.

1.2 Raspodela uzoraka po klasama

Na slici 2 prikazan je histogram broja uzoraka po klasama u trening skupu.



Slika 2: Histogram broja uzoraka po klasama u trening skupu.

Balansiranost skupa podataka

Skup sadrži 8000 slika ravnomerno raspoređenih u 10 klasa, što odgovara prosečno 800 uzoraka po klasi. Analiza histograma pokazuje da je raspodela uzoraka po klasama **uravnotežena** – broj primera po klasama je isti. S obzirom da klase nisu neuravnotežene, nije bila potrebna primena tehnika za balansiranje kao što su *oversampling*, *undersampling* ili ponderisanje klasa.

2 Predprocesiranje podataka

2.1 Skaliranje i normalizacija

Sve ulazne slike skaliraju se na dimenziju 128×128 piksela, što je definisano pri učitavanju podataka korišćenjem funkcije `image_dataset_from_directory`.

Normalizacija vrednosti piksela vrši se unutar modela kao poseban sloj:

```
layers.Rescaling(1./127.5, offset=-1)
```

Ovim se vrednosti piksela (opseg $[0, 255]$) preslikavaju u opseg $[-1, 1]$, što odgovara MobileNetV2 arhitekturi. Ovakva normalizacija ubrzava konvergenciju i stabilizuje gradijente tokom treniranja.

2.2 Augmentacija podataka

Kako bi se povećala raznovrsnost trening skupa i smanjio rizik od preobučavanja, primenjena je augmentacija podataka.

Primenjene transformacije i njihova svrha:

- **RandomFlip('horizontal')** – horizontalno obrtanje slike, čime se simulira varijacija u orijentaciji subjekta. Vertikalno obrtanje je izostavljeno jer naopako okrenuta osoba ne predstavlja validnu klasu akcije.
- **RandomRotation(0.05)** – nasumična rotacija do $\pm 18^\circ$, čime se model prilagođava blagim nagibima kamere.
- **RandomZoom(0.05)** – nasumično uvećanje ili smanjenje do 5%, što simulira različite udaljenosti subjekta od kamere.
- **RandomContrast(0.1)** – nasumična promena kontrasta do 10%, čime se poboljšava robustnost na različite uslove osvetljenja.

Augmentacija je namerno umerena – preterana augmentacija pokazala se kontraproduktivnom u ranijim verzijama modela, jer je unošenjem previše šuma degradirala i trening i validacionu tačnost.

3 Arhitektura modela

3.1 Transfer učenje – MobileNetV2

Umesto treniranja CNN mreže od nule, primenjen je pristup **prenosa znanja** (*transfer learning*) korišćenjem prethodno istrenirane MobileNetV2 arhitekture.

MobileNetV2 je laka konvolucionna mreža razvijena od strane Google-a, optimizovana za primene sa ograničenim računarskim resursima. Ključne karakteristike arhitekture su:

- *Depthwise separable convolutions* – razdvaja standardnu konvoluciju na depthwise i pointwise operaciju, drastično smanjujući broj parametara i računsku složenost.
- *Inverted residual blocks* sa linearnim bottleneck-om – proširuje kanale pre depthwise konvolucije, a zatim ih kompresuje, uz residualne veze koje olakšavaju propagaciju gradijenata.
- Ugrađeni BatchNormalization slojevi nakon svake konvolucije.

Prednosti: mali broj parametara ($\sim 2.2\text{M}$), brzo treniranje, dobra tačnost na standardnim zadacima klasifikacije.

Mane: optimizovan za brzinu, ne za maksimalnu tačnost; može biti inferioran u odnosu na EfficientNet ili ResNet arhitekture na složenijim skupovima podataka.

Prenos znanja primenjen je na sledeći način: MobileNetV2 je inicijalizovan težinama istreniranim na ImageNet skupu podataka (~1.2M slika, 1000 klasa). Originalni klasifikacioni slojevi su uklonjeni (`include_top=False`), a na izlaz konvolucione osnove dodat je novi klasifikator prilagođen konkretnom zadatku.

3.2 Celokupna arhitektura

```
model = Sequential([
    layers.Input(shape=(128, 128, 3)),
    data_aug,
    layers.Rescaling(1./127.5, offset=-1),
    cnn_deo,
    layers.GlobalAveragePooling2D(),
    layers.Dense(64, activation='relu'),
    layers.Dropout(0.3),
    layers.Dense(32, activation='relu'),
    layers.Dropout(0.3),
    layers.Dense(brklasa, activation='softmax')
])
```

Broj parametara

Kategorija	Broj parametara
Ukupno parametara	2 342 378
Trenabilni parametri (FC faza)	84 394
Zamrznuti parametri (MobileNetV2)	2 257 984

3.3 Izbor aktivacionih funkcija

- **ReLU** (*Rectified Linear Unit*) koristi se u skrivenim Dense slojevima. ReLU je standardni izbor jer je računski efikasan, ne pati od problema nestajućeg gradijenta za pozitivne vrednosti, i empirijski daje dobre rezultate u kombinaciji sa BatchNormalizationom.
- **Softmax** koristi se u izlaznom sloju sa 10 neurona. Softmax transformiše izlaze u raspodelu verovatnoća, gde je suma svih 10 izlaza jednaka 1, što direktno odgovara verovatnoći pripadnosti svakoj od klasa.

3.4 Kriterijumska funkcija

Korišćena kriterijumska funkcija je **Sparse Categorical Cross-Entropy**:

$$\mathcal{L} = - \sum_{i=1}^N \log \hat{p}_{i, y_i} \quad (1)$$

gde je $\hat{p}_{i,y_i}$ prediktovana verovatnoća tačne klase y_i za i -ti uzorak. Ova funkcija je standardni izbor za višeklasnu klasifikaciju kada su oznake klasa celobrojne (ne one-hot kodirane), što je ovde slučaj.

3.5 Optimizaciona metoda

Za minimizaciju funkcije greške korišćen je **Adam** (*Adaptive Moment Estimation*) optimizier. Adam adaptivno podešava stopu učenja za svaki parametar zasebno koristeći prvu i drugu procenu momenta gradijenata. Stopa učenja 10^{-3} (podrazumevana) korišćena je u fazi treniranja FC slojeva, dok je za fine-tuning fazu stopa smanjena na 10^{-5} radi stabilnijeg ažuriranja zamrznutih slojeva MobileNetV2.

4 Procedura treniranja

4.1 Faza 1: Treniranje FC dela

U prvoj fazi, svi slojevi MobileNetV2 baze su zamrznuti (`cnn_deo.trainable = False`), a treniraju se isključivo novi Dense slojevi. Ovim se konvolucionni feature extractor čuva netaknutim i iskorišćavaju naučene reprezentacije sa ImageNet skupa podataka. Treniranje je izvršeno do 30 epoha uz *Early Stopping* koji prati validacioni gubitak sa strpljenjem (*patience*) od 5 epoha.

Treniranje je zaustavljeno na **epohi 14**, uz obnavljanje težina iz epohe 9 kao najboljeg modela.

4.2 Faza 2: Fine-tuning

Nakon inicijalnog treniranja, pristupljeno je fine-tuningu: odmrznuti su **svi slojevi** MobileNetV2 baze, izuzev BatchNormalization slojeva koji su ostavljeni zamrznuti radi stabilnosti:

```
for layer in cnn_deo.layers:
    layer.trainable = True
for layer in cnn_deo.layers:
    if isinstance(layer, layers.BatchNormization):
        layer.trainable = False
```

Korišćena je mala stopa učenja 10^{-5} kako se ne bi narušile pretrenirane težine. Early Stopping je praćen validacionu tačnost sa strpljenjem od 5 epoha. Treniranje je zaustavljeno na **epohi 15**, uz obnavljanje težina iz epohe 10.

5 Zaštita od preobučavanja

Preobučavanje (*overfitting*) je pojava kada model previše nauči specifičnosti trening skupa, uključujući šum i slučajne obrasce koji nisu generalizabilni. Takav model postiže visoku tačnost na trening skupu, ali značajno lošiju na novim,

nevidenim podacima. Tipičan znak preobučavanja je veliki raskorak između trening i validacione tačnosti.


5.1 Primenjene metode zaštite

- **Dropout (0.3):** Nakon svakog Dense sloja dodat je Dropout sloj koji nasumično deaktivira 30% neurona u svakoj iteraciji treniranja. Na taj način se smanjuje međuzavisnost neurona i podstiče mreža da nauči robusnije i generalnije reprezentacije.
- **Augmentacija podataka:** Nasumične transformacije slike (flip, rotacija, zum, kontrast) efektivno povećavaju raznovrsnost trening skupa, čineći ga težim za memorisanje.
- **Early Stopping:** Treniranje se automatski prekida kada se validaciona metrika prestane poboljšavati, uz restauraciju težina iz najboljeg momenta. Ovo direktno sprečava dalje preobučavanje.

6 Rezultati

6.1 Krive gubitka i tačnosti tokom treniranja


Na slikama ispod prikazane su krive gubitka i tačnosti tokom obe faze treniranja (FC faza i fine-tuning faza).



(a) Gubitak – FC faza

(b) Tačnost – FC faza

Slika 3: Promene gubitka i tačnosti tokom treniranja FC dela.



Slika 4: Promene gubitka i tačnosti tokom fine-tuning faze.

6.2 Performanse klasifikacije

6.2.1 Trening skup

Ukupna tačnost na trening skupu iznosi **87.86%**.

Tabela 1: Izveštaj klasifikacije – trening skup

Klasa	Preciznost	Osetljivost	F1-skor	Podrška
clapping	0.95	0.73	0.83	661
cycling	0.93	0.99	0.96	654
dancing	0.80	0.89	0.84	634
eating	0.93	0.96	0.94	626
fighting	0.88	0.75	0.81	638
hugging	0.80	0.90	0.85	639
laughing	0.84	0.89	0.86	626
running	0.91	0.85	0.88	636
sleeping	0.91	0.91	0.91	647
using_laptop	0.88	0.92	0.90	639
Makro prosek	0.88	0.88	0.88	6400

6.2.2 Validacioni skup

Ukupna tačnost na validacionom skupu iznosi **80.56%**.

Tabela 2: Izveštaj klasifikacije – validacioni skup

Klasa	Preciznost	Osetljivost	F1-skor	Podrška
clapping	0.79	0.58	0.67	139
cycling	0.87	0.99	0.92	146
dancing	0.78	0.85	0.81	166
eating	0.90	0.90	0.90	174
fighting	0.83	0.62	0.71	162
hugging	0.70	0.84	0.76	161
laughing	0.78	0.80	0.79	174
running	0.85	0.75	0.80	164
sleeping	0.78	0.86	0.82	153
using_laptop	0.81	0.84	0.83	161
Makro prosek	0.81	0.80	0.80	1600


6.2.3 Test skup

Ukupna tačnost na test skupu iznosi **80.79%**.


Tabela 3: Izveštaj klasifikacije – test skup

Klasa	Preciznost	Osetljivost	F1-skor	Podrška
clapping	0.89	0.57	0.70	42
cycling	0.95	1.00	0.98	40
dancing	0.72	0.72	0.72	40
eating	1.00	0.98	0.99	42
fighting	0.74	0.70	0.72	40
hugging	0.69	0.90	0.78	40
laughing	0.72	0.78	0.75	40
running	0.83	0.72	0.77	40
sleeping	0.82	0.86	0.84	42
using_laptop	0.77	0.85	0.81	40
Makro prosek	0.81	0.81	0.81	406

6.3 Matrice konfuzije



Slika 5: Matrica konfuzije na trening skupu.



Slika 6: Matrica konfuzije na test skupu.

6.4 Primeri dobro i loše klasifikovanih slika



Slika 7: Primeri klasifikovanih slika iz test skupa sa prikazanom tačnom i prediktovanom klasom.

7 Zaključak

Model postiže tačnost od **80.79%** na test skupu, što predstavlja zadovoljavajuće performanse za 10-klasni problem klasifikacije akcija. Razlika između trening (87.86%) i test tačnosti (80.79%) iznosi oko 7 procentnih poena, što je prihvatljiv gap i ukazuje na umerenu generalizaciju bez izrazitog preobučavanja.

Klase koje se najuspešnije klasifikuju su *cycling* ($F1 = 0.98$) i *eating* ($F1 = 0.99$), jer poseduju jasne i specifične vizuelne karakteristike – prisustvo bicikla, odnosno hrane. Klasa *clapping* ($F1 = 0.70$) pokazuje najslabije performanse, što je posledica vizuelne sličnosti sa *hugging*, *laughing* i *dancing* – sve su to akcije koje uključuju osobe u uspravnom položaju sa sličnom pozom tela. Klase *fighting* i *hugging* se međusobno često mešaju iz istog razloga.

Primena fine-tuninga doprinela je značajnom poboljšanju: tačnost je porasla sa 76.5% (nakon FC faze) na 80.56% na validacionom skupu. Takođe, razlika između performansi validacionog i test skupa je gotovo zanemarljiva, što ukazuje na stabilnu generalizaciju na neviđenim podacima.